

Badanie gier kooperacyjnych z niepełną informacją na przykładzie gry Hanabi

(A study on cooperative games with incomplete information based on the game of Hanabi)

Wojciech Jarząbek

Jacek Leja

Praca inżynierska

Promotor: dr Paweł Rychlikowski

Uniwersytet Wrocławski
Wydział Matematyki i Informatyki
Instytut Informatyki

26 stycznia 2020

Streszczenie

...

...

Spis treści

1. Wprowadzenie	5
1.1. Czym jest Hanabi?	5
1.2. Hanabi a sztuczna inteligencja	6
2. Reguły gry	7
2.1. Wyjaśnienie zasad	8
2.2. Dodatkowe obserwacje	9
3. Strategie sztucznej inteligencji	11
3.1. Podejście regułowe	11
3.2. Drzewa poszukiwań	12
3.3. Algorytmy uczące	12
3.4. Naginanie zasad gry	13
4. Strategie w praktyce	15
4.1. Cheater	16
4.2. SmartCheater	17
4.3. Erratic	19
4.4. StoppedClock	20
4.5. SimpleDistrustful	22
4.6. Distrustful	23
4.7. Trustful	27
4.8. BayesianTrustful	31
4.9. Reinforced	34

5. Niestandardowe modele rozgrywki	35
5.1. Dwa oblicza drużyn Hanabi	35
5.2. Pojedynki XY	35
6. Dalsze badania	36
A Uruchamianie interfejsu użytkownika	37
Bibliografia	38

Rozdział 1.

Wprowadzenie

1.1. Czym jest Hanabi?

Gry planszowe to forma rozrywki, która towarzyszy człowiekowi od tysięcy lat. Były one popularne już za czasów antycznych, czego dowodzi chociażby malowidło z 3300 r. p.n.e, pochodzące z grobowca Merknery, na którym ukazano rozgrywkę Seneta. Przykładem może być także Królewska Gra z Ur, której egzemplarze odnaleziono w trakcie badań nad starożytną Mezopotamią. Choć gry te zostały w dzisiejszych czasach w znacznej mierze zapomniane, nie sposób nie wspomnieć o innych z podobnego okresu, takich jak warcaby czy Go, a także o nieco młodszych szachach, które wciąż cieszą się ogromną i niesłabnącą popularnością.

Każdą z tych gier łączy aspekt rywalizacji: pod koniec rozgrywki jednoznacznie wyszczególnia się jednego lub więcej graczy, których określamy mianem zwycięzców, zaś reszta - przegrywa. Inne podejście prezentują gry kooperacyjne, gdzie zadaniem nie jest pokonanie innych uczestników zabawy, a osiągnięcie wspólnego celu, który gwarantuje wygraną. Można powiedzieć, że przeciwnikiem graczy jest w tym przypadku sama gra, która swoją konstrukcją skłania do współpracy. Pierwsze gry tego typu powstały dopiero w drugiej połowie XX wieku i początkowo miały wyłącznie charakter edukacyjny. Wraz z popularyzacją tzw. "planszówek", gry kooperacyjne w znacznym stopniu zyskały na popularności, a ich forma wyewoluowała w kierunku zabawy kładącej nacisk na aspekty towarzyskie, które ograniczają lub wręcz odrzucają współzawodnictwo. Przykładami takiego podejścia mogą być Pandemic, Martwa Zima, a także Hanabi.

Hanabi (jap. fajerwerki) to w pełni kooperacyjna gra planszowa, która w 2013 roku wygrała prestiżową nagrodę Spiel des Jahres. Gracze wcielają się w niej w pracowników fabryki fajerwerków, w której omyłkowo zostały pomieszane ze sobą różne rodzaje prochu. Celem jest złożenie w odpowiedniej kolejności możliwie jak największej ilości sztucznych ogni, które gracze otrzymują poprzez dobieranie kart z potasowanej talii. Uczestnicy rozgrywki widzą karty, które są w posiadaniu innych graczy,

lecz nie mogą przypatrywać się tym, którymi sami dysponują. Dodatkowo, komunikacja odnosząca się do treści kart podlega restrykcyjnym zasadom i jest w znacznym stopniu ograniczona, co czyni rozgrywkę nietrywialną. Jakie strategie należy zatem zastosować, by wygrać? Jak można przełożyć je na świat algorytmów?

1.2. Hanabi a sztuczna inteligencja

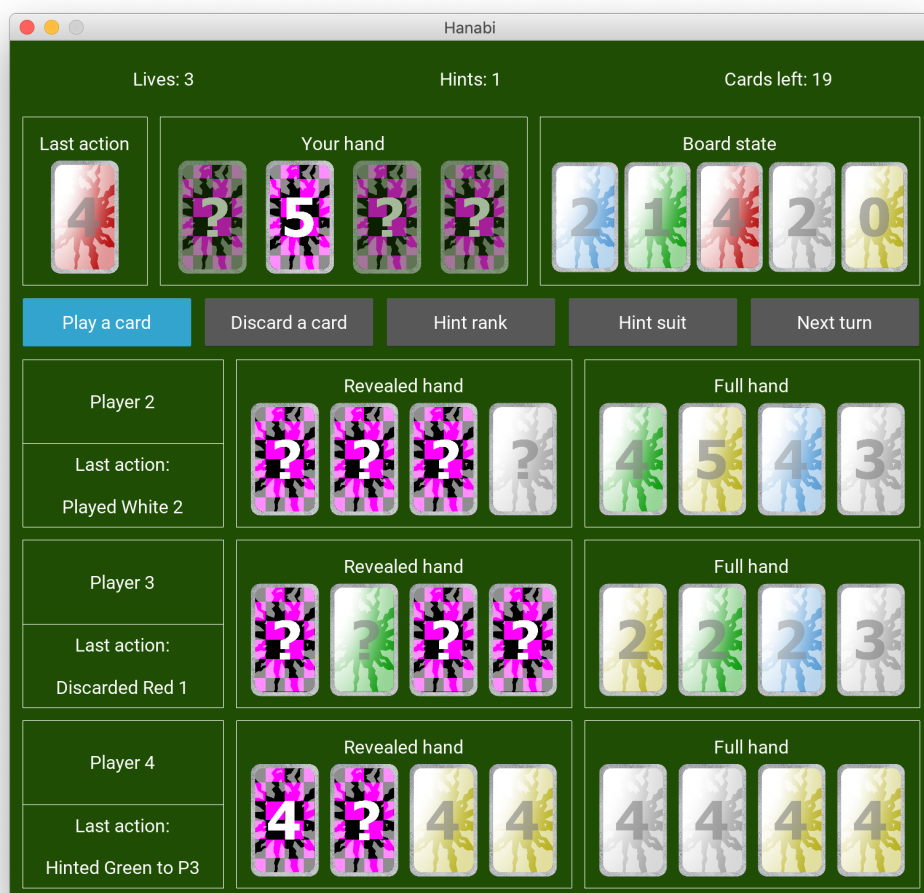
W teorii gier istnieje pojęcie perfekcyjnego zagrania, czyli pojedynczego ruchu zależnego od aktualnego etapu gry, prowadzącego do stanu rozgrywki maksymalizującego oczekiwany wynik, niezależnie od ruchów, które mogą w odpowiedzi wykonać inni gracze. Perfekcyjne zagrania są podstawą optymalnego planu działania, minimalizującego możliwe straty ponoszone w trakcie rozgrywania danej partii. Niestety, tak silna strategia - w przypadku złożonych gier - jest nieprawdopodobnie trudna do uzyskania ze względu na ogromną rozpiętość drzewa możliwych do uzyskania stanów rozgrywki. W praktyce używa się algorytmów: heurystycznych, regulowych, opartych na technikach uczących, nadużywających zasad gry lub siłowych. Przykładowo, słynny komputer Deep Blue, który w maju 1997 roku pokonał ówczesnego mistrza świata w szachach, Garrego Kasparova, nie posiadał optymalnej strategii. Używał on w zamian metody siłowej, wspomaganą algorytmem przeszukującym alfa-beta, rozpatrując wszystkie możliwe zagrania i wybierając te, które dawały mu największą przewagę lokalną. Takie podejście było możliwe z racji na ogromną moc superkomputera, który potrafił rozpatrywać 200 milionów ruchów na sekundę.

Stworzenie agentów sztucznej inteligencji do Hanabi to zadanie, które wymaga pokonania trudności niespotykanych w innych grach. Jest to następstwo kilku czynników: niepełnej informacji, losowości dobieranych kart, a także ograniczonych zasobów, m.in. w postaci podpowiedzi dla innych graczy. Agenci muszą współpracować, gdyż gracz, który odmawia kooperacji, może w kilku ruchach doprowadzić do przegranej całej grupy. Ważne jest, by nie marnować zasobów, a zatem sztuczna inteligencja musi być odpowiednio skoordynowana. Ponadto, znikoma ilość kart w talii nie pozwala na zbyt długą rozgrywkę - oznacza to zatem, że aby zdążyć z wygraną, agenci muszą posiadać protokół komunikacji, który dopuszcza przekazywanie w obrębie zasad gry dodatkowych, implicytnych informacji, rozumianych przez pozostałych jej uczestników.

Niniejsza praca ma na celu zbadanie Hanabi jako gry kooperacyjnej z niepełną informacją. Będziemy analizować techniki tworzenia agentów sztucznej inteligencji grających w Hanabi, którzy wykonują możliwie najbardziej efektywne i zrozumiałe dla ludzi ruchy na tyle szybko, by umożliwić komfortową rozgrywkę z człowiekiem na zwykłych komputerach.

Rozdział 2.

Reguły gry



Rysunek 2.1: Interfejs graficzny do gry Hanabi, utworzony na potrzeby projektu (twórca grafik: Jakub Podwysocki)

2.1. Wyjaśnienie zasad

Celem gry jest zdobycie możliwie największej ilości punktów poprzez poprawne zagrywanie kart. Maksymalna ilość możliwych do uzyskania punktów wynosi dwadzieścia pięć. Po zakończeniu gry ilość uzyskanych punktów oblicza się poprzez zsumowanie wartości najwyższych kart z każdego ze stosów odpowiedniego koloru.

Talia do gry składa się z pięćdziesięciu kart. Każda karta jest oznaczona jednym z pięciu kolorów (czerwony, żółty, niebieski, biały, zielony) oraz jedną z wartości z zakresu od 1 do 5. Dla każdego koloru istnieją po trzy karty o numerze 1, po dwie karty o numerach 2, 3 i 4, a także po jednej karcie o numerze 5.

Na początku gry talia jest tasowana. Gracze rozpoczynają rozgrywkę z ośmioma żetonami podpowiedzi i trzema żetonami życia. Żetony te są wspólne dla wszystkich uczestników rozgrywki. Jeżeli graczy jest dwóch lub trzech, każdy z nich dobiera po pięć zakrytych kart. Jeżeli jest ich czterech lub pięciu, dobierają po cztery zakryte karty. Następnie gracze po kolei wykonują swoje ruchy. Ruchu nie można pominąć. Ruch to wykonanie jednej z trzech dostępnych akcji:

1. Zagranie karty:

Gracz deklaruje chęć zagrania karty, wybiera zakrytą ze swojej ręki, a następnie wyklada ją na planszę w pozycji odkrytej. Zagranie może być poprawne lub niepoprawne. Karty muszą być zagrywane w kolejności rosnącej, zaczynając od jedynki, inaczej zagranie uważa się za niepoprawne. Przykładowo, jeśli na planszy nie ma żadnych kart, można poprawnie zagrać tylko te, które są oznaczone numerem 1. Jeżeli na planszy znajdują się wyłącznie nie jedna niebieska karta o numerze 1 i stos żółtych kart, spośród których największą wartość ma karta o numerze 4, można poprawnie zagrać niebieską kartę o numerze 2, żółtą kartę o numerze 5 lub dowolną kartę innego koloru o numerze 1. Jeżeli karta została zagrana poprawnie, jest ona dodawana do stosu o odpowiednim kolorze lub też rozpoczyna stos swojego koloru, jeżeli jest to karta o numerze 1. Dodatkowo, jeżeli zagrana karta ma numer 5, gracze otrzymują jeden żeton podpowiedzi (chyba, że mają ich już osiem - wtedy zagranie nie ma żadnego dodatkowego efektu). Jeżeli karta została zagrana niepoprawnie, jest ona usuwana z gry i nie jest dodawana do żadnego ze stosów, a gracze tracą jeden z żetonów życia. Po rozpatrzeniu efektów akcji gracz dobiera zakrytą kartę z talii (jeżeli nie jest ona pusta).

2. Odrzucenie karty:

Gracz deklaruje chęć odrzucenia karty, wybiera zakrytą ze swojej ręki, a następnie wyklada ją na planszę w pozycji odkrytej. Karta ta jest usuwana z gry, bez dokładania jej do któregośkolwiek ze stosów, a gracze otrzymują jeden żeton podpowiedzi (chyba, że mają ich już osiem - wtedy odrzucenie karty

nie ma żadnego dodatkowego efektu). Po rozpatrzeniu efektów akcji gracz dobiera zakrytą kartę z talii (jeżeli nie jest ona pusta).

3. Udzielenie podpowiedzi innemu graczowi:

Gracz usuwa jeden z żetonów podpowiedzi, po czym wybiera innego uczestnika rozgrywki oraz jeden z dwóch rodzajów informacji, których chce mu udzielić: może wskazać wszystkie jego karty o wybranym kolorze lub wszystkie jego karty o wybranym numerze. Akcji tej nie można wykonać, jeśli w grze nie ma żadnych żetonów podpowiedzi, gdyż wiązałoby się to z koniecznością usunięcia żetonu podpowiedzi, który nie istnieje. Udzielanie graczom podpowiedzi dotyczących kart w jakikolwiek inny sposób jest zabronione.

Jeżeli któryś z graczy dobierze ostatnią kartę z talii, każdy uczestnik rozgrywa jedną dodatkową turę (wraz z graczem, który dobrał ostatnią kartę), po czym gra się kończy.

Gra natychmiast kończy się, gdy zostanie utracony ostatni żeton życia lub gdy wszystkie stosy odpowiednich kolorów zostaną skompletowane (czyli na każdy z nich poprawnie położono kartę o numerze 5).

2.2. Dodatkowe obserwacje

Partie na dwóch graczy cechują się bardzo wysokim stopniem trudności. Uczestnicy rozgrywki znacznie częściej muszą radzić sobie ze skomplikowanymi sytuacjami, które wynikają z niekorzystnych rozdań. Fakt ten jest spotęgowany przez znikomą ilość dostępnych informacji (każdy z graczy widzi naraz tylko pięć kart), a także łatwość wpadnięcia w cykl, w którym jeden z graczy udziela podpowiedzi, a drugi zagrywa lub odrzuca karty.

Z powodu losowej natury gry, niektórych rozdań nie da się wygrać z maksymalną ilością punktów. Najprostsza taka sytuacja ma miejsce, gdy w rozgrywce na dwóch graczy jeden z nich dobierze same karty o numerze 5, drugi dobierze wyłącznie karty o numerze 4, a na górze talii znajdują się pozostałe karty o numerze 4. Aby uzyskać dostęp do kart o innych numerach, gracze muszą odrzucić (lub niepoprawnie zagrać) co najmniej sześć kart. Z zasady szufladkowej Dirchleta można wywnioskować, że wszystkie kopie co najmniej jednej z kart danego rodzaju zostaną bezpowrotnie usunięte z gry, bez umieszczania ich na stosie, co uniemożliwia wygraną.

Ze względu na ograniczony rozmiar talii, zagrywanie wyłącznie tych kart, o których posiada się komplet informacji, jest wysoce nieefektywne. Po rozdaniu kart talia zawiera od 30 do 40 kart, zależnie od liczby graczy. Aby uzyskać najwyższy wynik, należy zagrać aż 25 kart, a zagranie każdej z nich oznacza zmniejszenie rozmiaru talii o jeden. Oznacza to (zakładając, że gracze próbują uzyskać 25 punktów), że można

wykonać maksymalnie od 10 do 17 ruchów, w których odrzuca się kartę, wliczając w to tury po opróżnieniu talii. Po doliczeniu początkowych 8 żetonów daje to maksymalną ilość 25 podpowiedzi. Oznacza to, że w grze na dwie osoby każda podpowiedź musi jednoznacznie ujawniać średnio po jednej karcie, lecz każda z nich potrzebuje dwóch podpowiedzi różnego rodzaju, by uzyskać pełną informację. Przy pięciu graczach każda podpowiedź musi średnio ujawniać już nie jedną, a prawie półtorej karty.

Ponadto, jeżeli chcemy odrzucać wyłącznie karty, które można bezpiecznie usunąć z gry, inni gracze muszą nam zakomunikować ich brak przydatności poprzez odpowiednie podpowiedzi (lub ich brak, co jest w znacznym stopniu utrudnione przez konieczność udzielania pełnej informacji o zawartości rąk współuczestników). Karty bezużyteczne mogą, lecz nie muszą zostać ujawnione w drodze przypadku, podczas ujawniania innych kart. W rezultacie najczęściej przyjmowaną konwencją wśród graczy jest odrzucanie najstarszej karty w ręce: jeżeli żaden z uczestników rozgrywki nie ostrzega przed usunięciem jej z gry, istnieje wysokie prawdopodobieństwo, że jest ona nieprzydatna.

Rozdział 3.

Strategie sztucznej inteligencji

3.1. Podejście regułowe

Podczas realnej rogrzywki Hanabi gracze nie dysponują komputerem, który pomógłby im w wykonywaniu ruchów poprzez dokonywanie odpowiednich obliczeń. Zamiast tego korzystają oni z wiedzy nabytej w trakcie rozegranych już partii, modyfikując swoje strategie i rozszerzając je o kolejne elementy, aż do osiągnięcia zadowalającego ich poziomu wiedzy o grze. Proces ten w naturalny sposób prowadzi do wykształcenia konwencji (takich jak: “należy zawsze odrzucać najstarszą kartę w ręce”), a także do opracowania systemu reguł, pomocnych w uzyskiwaniu wysokich wyników (przykładowo: “jeżeli ktoś chce odrzucić ważną kartę, należy go powstrzymać poprzez udzielenie odpowiedniej podpowiedzi”). Zasady te można przełożyć na algorytmy, co prowadzi do utworzenia systemów regułowych, znanych także jako eksperckie.

Algorytmy regułowe to programy, które poprzez procesy decyzyjne naśladują wybory, których w danych sytuacjach mógłby dokonać człowiek. Są one najczęściej deterministyczne, co jest cechą szczególnie ważną w środowiskach, które wymagają koordynacji i przewidywania działań podejmowanych przez inne elementy systemu. W przypadku agentów sztucznej inteligencji, algorytmy regułowe powielają zachowania prawdziwych graczy.

Z racji na kooperacyjną konstrukcję Hanabi, sama emulacja typowych zachowań ludzkich graczy nie wystarcza jednak, by wygrać. Potrzebna jest także odpowiednia koordynacja działań pomiędzy agentami: strategia. Gracze muszą zwracać uwagę na współuczestników rozgrywki i na bieżąco interpretować ich poczynania, by móc wywnioskować, jaka seria ruchów doprowadzi do najlepszej możliwej sytuacji. Prostym i efektywnym sposobem na zaimplementowanie strategii jest wyspecyfikowanie protokołu komunikacji pomiędzy agentami, który nadaje niektórym zagraniam dodatkowe znaczenie, rozumiane przez pozostałych graczy. Przykładowo, dobrym pomysłem może być zasada o następującej treści: “jeżeli inny gracz podpo-

wiedział mi bez wyraźnej przyczyny jeden z kolorów, ujawniając w ten sposób kilka kart, najprawdopodobniej mogę je zagrać, w kolejności od lewej do prawej”. Z tego powodu implementacja agentów regułowych wiąże się z koniecznością bardzo dobrej znajomości zasad rządzących grą.

3.2. Drzewa poszukiwań

Istnieją dwa główne czynniki, które sprawiają, że analiza stanu gry w Hanabi jest trudnym zadaniem. Są to: niepełna informacja o aktualnym etapie rozgrywki, a także losowość kart dobieranych z talii. Udowodniono, że nawet w uproszczonej wersji gry, w której uczestnicy mogą patrzeć na swoje karty, problem perfekcyjnego zagrania jest NP-kompletny[1]. Sprawia to, że podejście do zagadnienia w sposób siłowy jest nieefektywne. Fakt ten, połączony z trudnością opracowania funkcji oceniającej jakość zagrania, wyklucza użycie części możliwych rozwiązań problemu, takich jak algorytm alfa-beta.

Aby obejść trudność znalezienia perfekcyjnego zagrania, grupa Facebook Research zaproponowała rozwiązanie bazujące na drzewie poszukiwań Monte Carlo[2]. Każdy z graczy dysponuje zbiorem predefiniowanych akcji, które dostosowuje odpowiednio do aktualnego stanu rozgrywki poprzez analizę prawdopodobieństwa zagrań, które mogą wykonać współuczestnicy. Algorytm bierze pod uwagę także szanse aktualnego gracza na posiadanie w ręce kart, które mogły zostać wylosowane z talii. Aby przyspieszyć działanie programu, głębokość drzewa poszukiwań jest ograniczana, a agenci wykonują predefiniowane akcje i nie eksplorują nowych opcji, jeżeli wiązałoby się to z przekroczeniem zadanego limitu obliczeń.

Takie podejście pozwala na uzyskanie bardzo wysokich wyników, sięgających nawet 24.61 punktów w rozgrywce dla dwóch graczy. Działanie algorytmu jest jednak kosztowne obliczeniowo, nawet przy znacznym ograniczeniu zakresu dokonywanych poszukiwań. Do osiągnięcia tak wysokiej punktacji potrzeba olbrzymich ilości obliczeń, które, z racji na możliwość ich zrównoleglenia, są najczęściej dokonywane na nowoczesnych kartach graficznych. Wyłączenie agentom możliwości dokonywania dodatkowych poszukiwań degeneruje ich do postaci agentów regułowych, które, choć na każdą akcję potrzebują zużycia istotnie mniejszej ilości zasobów, wciąż osiągają imponujący wynik 23 punktów.

3.3. Algorytmy uczące

Innym sposobem na zaimplementowanie programu grającego w Hanabi jest użycie algorytmów uczących, które łączą zalety podejść regułowych i poszukujących. Jak sugeruje nazwa, polegają one na symulowaniu procesu akumulacji doświadczenia, podobnego do tego doznawanego przez ludzkich graczy. W toku ewolucji agent

zdobywa wiedzę o środowisku, w którym operuje, dostosowując się do zmieniających warunków, wypracowując i udoskonalając sposoby radzenia sobie w zaprezentowanych sytuacjach. Tworzenie algorytmów uczących nie wymaga ani szerokiej wiedzy o zawiłościach zasad gry, ani kosztownych obliczeń, które byłyby wykonywane w trakcie rozgrywki.

Wadą tego podejścia jest konieczność wyuczenia agenta odpowiednich zachowań. Odbywa się to poprzez zapewnienie mu zestawu danych, na których mógłby zdobyć doświadczenie. W zależności od uzyskiwanych wyników, decyzje algorytmu są nagradzane lub karane. Dobranie odpowiednio różnorodnego zbioru uczącego, w parze z funkcjami kwalifikującymi, pozwala programowi nie tylko na rozpoznawanie i radzenie sobie z najczęściej występującymi sytuacjami, ale i generalizację zachowań, potrzebną do wybrnięcia ze stanów gry, które nie zostały dotychczas napotkane.

Należy mieć na uwadze, że nieodpowiedni dobór zbioru uczącego lub funkcji, które oceniają poczynania agenta, potrafi doprowadzić do anomalii w procesie zdobywania wiedzy. Jeżeli zestawy testowe będą zbyt homogeniczne i zbyt liczne w stosunku do osiągalnej liczby stanów rozgrywki, może dojść do przeuczenia modelu, z kolei zbyt krótka nauka nie przygotowuje programu do nietypowych sytuacji. Nieprawidłowości w procedurach klasyfikujących, choć mniej zauważalne, także potrafią doprowadzić do niepożądanych sytuacji, tak jak miało to miejsce w przypadku programu grającego w produkcje na platformę Nintendo Entertainment System. Agent ten, nie chcąc doprowadzić do przegranej, nauczył się wstrzymywać rozgrywkę na zawsze[3].

3.4. Naginanie zasad gry

W oficjalnych zasadach gry nie ma wyszczególnionego przymusu udzielania odpowiedzi, które ujawniałyby jakiejkolwiek karty. Jeżeli wybierzemy gracza, który nie posiada żadnych czerwonych kart i zdecydujemy się na podpowiedzenie mu czerwonego koloru, tura jest pomijana za cenę żetonu podpowiedzi. Choć taki ruch wydaje się nie mieć sensu, gdyż podpowiedź można wykorzystać w produktywny sposób, otwiera on możliwość poważnego nagięcia zasad gry. Jeżeli każdej z możliwych podpowiedzi przypiszemy unikatową wartość numeryczną, możemy za ich pomocą przekazywać innym graczom informacje liczbowe. Jest to powód, dla którego możliwość udzielania pustych podpowiedzi jest uznawana w społeczności graczy Hanabi za kontrowersyjną, toteż w niektórych edycjach gry została ona zakazana.

Fakt ten można wykorzystać do stworzenia agenta, który za pomocą pozornie bezwartościowych ruchów udziela podpowiedzi wszystkim graczom jednocześnie. Korzysta on ze słynnej zagadki logicznej, znanej jako problem więźniów i kapeluszy, odpowiednio uogólnionej i dopasowanej do liczby graczy. Agent, który rozgrywa aktualną turę, oblicza idealne zagrania dla innych uczestników rozgrywki, po czym szyfruje je do postaci liczbowej. Kolejni gracze, znając podaną przez poprzednika

wartość, po rozpatrzeniu optymalnych zagrań innych graczy, są w stanie wywnioskować, jaki ruch powinni wykonać.

Według badań z 2017 roku[4], agent ten uzyskuje maksymalną ilość punktów średnio w 92% rozgrywanych gier, co jest wynikiem bliskim optymalnemu. Jest to imponujący rezultat, zarówno ze względu na bardzo szybkie działanie algorytmu, jak i jego nadzwyczajną efektywność.

Niestety, taki sposób gry całkowicie zawodzi, gdy jeden z graczy wyłamie się z konwencji narzuconej przez protokół komunikacji. Dodatkowo, algorytm działa wyłącznie w rozgrywce na czterech oraz pięciu graczy, gdyż głównym powodem jego sukcesu jest możliwość przekazywania w każdej z odpowiedzi maksymalnej ilości informacji, toteż zmniejszenie liczby graczy powoduje znaczne zredukowanie efektywności ruchów. Są to powody, dla których agent ten nie nadaje się do rozgrywki z człowiekiem.

Rozdział 4.

Strategie w praktyce

W celu zbadania zaprezentowanych sposobów tworzenia sztucznej inteligencji, która potrafiłaby grać w Hanabi, zaimplementowaliśmy dziewięciu agentów. Aby umożliwić testowanie ich możliwości, opracowaliśmy także graficzny interfejs (patrz: Rysunek 2.1), pozwalający użytkownikowi na aktywne uczestnictwo w rozgrywce, złożonej z dowolnie dobranej przez niego składu graczy komputerowych.

Siedmiu agentów jest opartych o systemy regułowe, różniące się stopniem awansowania wdrażanych strategii. Aby usprawnić działanie jednego z agentów regułowych, użyliśmy bayesowskiej metody optymalizacji hiperparametrów, korzystającej z procesów gaussowskich. Ostatni z zaprezentowanych agentów stosuje algorytm uczący ze wzmocnieniem, oparty o funkcje heurystyczne generalizujące stan gry, wspomagane procesami decyzyjnymi Monte Carlo.

Systemy zasad zostały oparte o nasze własne spostrzeżenia, których doszukaaliśmy się poprzez obserwację rozgrywek ludzkich graczy i uznaliśmy za kluczowe do gry na wysokim poziomie. Każdy kolejny agent regułowy bazuje na conceptach, które zostały użyte do zbudowania jego poprzedników, i usprawnia je. Takie podejście prowadzi do naturalnej progresji prezentowanych warstw abstrakcji.

Nomenklatura

- μ — średnia arytmetyczna
- $\tilde{\mu}$ — mediana
- σ^2 — wariancja
- σ — odchylenie standardowe

4.1. Cheater

Cheater jest agentem, którego strategia polega na bezmyślnym oszukiwaniu. Program zawsze posiada komplet informacji o kartach, którymi dysponuje, lecz nie wykorzystuje dostępnej mu wiedzy w optymalny sposób: zagrywa karty, gdy to możliwe, w przeciwnym wypadku losowo je odrzuca.

Nowe pojęcia

- **Legalna akcja:**

Jeżeli wybrana akcja może być wykonany w danym momencie rozgrywki, jest ona legalna, niezależnie od poprawności. Przykładowo: udzielenie informacji w momencie, w którym na planszy nie znajduje się ani jeden żeton podpowiedzi, jest nielegalne. Jeżeli akcja jest nielegalna, korespondująca z nią część algorytmu kończy się niepowodzeniem.

- **Ujawniona karta:**

Jeżeli gracz jest w posiadaniu karty, o której posiada komplet informacji, kartę tę określimy jako ujawnioną.

- **Bezpieczna akcja:**

Jeżeli gracz może wykonać ruch, który nie doprowadzi do utraty żetonów życia, taką akcję określimy jako bezpieczną.


- **Bezpieczne zagranie:**

Jeżeli gracz posiada ujawnioną kartę, którą może bezpiecznie (czyli poprawnie) położyć na planszy, wykonanie takiej akcji nazwiemy bezpiecznym zagranie.

Schemat działania

1. Podejrzuj posiadane karty.
2. Jeżeli posiadasz bezpieczne zagranie, wykonaj je.
3. Odrzuć losową kartę.

Osiągi



Rysunek 4.1: Wyniki agenta Cheater (rozmiar próby: 1000 gier)

Uzyskane wyniki są bardzo dobre, lecz cechują się stosunkowo wysoką wariancją. Agenci są skłonni do odrzucania kluczowych kart i nie zwracają uwagi na fakt, że może to znacząco utrudnić lub nawet uniemożliwić dalsze zdobywanie punktów.

4.2. SmartCheater

SmartCheater dodaje głębiej poczynaniom agenta Cheater. Program zawsze posiada komplet informacji o kartach, którymi dysponuje, i wykorzystuje tę wiedzę w sposób bliski optymalnemu, stosując strategię przedłużającą rozgrywkę. Agent potrafi oceniać przydatność kart i za wszelką cenę unika ruchów, które utrudniają lub uniemożliwiają wygraną.

Nowe pojęcia

- Zagranie lawinowe:

Jeżeli położenie karty na planszy pozwala innym graczom na wykonywanie nowych ruchów, które kontynuują dokładanie kart do stosów, takie zagranie

nazwiemy lawinowym. Przykładowo: jeżeli aktualny gracz poprawnie zagra czerwoną kartę o numerze 1, zaś dwaj kolejni gracze posiadają kolejno czerwone karty o numerach 2 i 3, zagranie jest lawinowe.

- Bezużyteczna karta:

Jeżeli nie istnieje możliwość poprawnego zagrania karty, jest ona bezużyteczna i może być odrzucona bez żadnych konsekwencji. Przykładowo: gdy stos kart koloru zielonego jest w pełni ułożony, nie można poprawnie zagrać żadnych dodatkowych kart koloru zielonego.

- Karta krytyczna:

Jeżeli karta nie jest bezużyteczna, a jej odrzucenie wiąże się z niemożnością zagrania przez któregokolwiek z graczy innej jej kopii, karta jest krytyczna. Przykładowo: każda karta o numerze 5 jest krytyczna.


- Spasowanie tury:

Jeżeli na planszy znajduje się co najmniej jeden żeton podpowiedzi, udzielenie losowej podpowiedzi dowolnemu z graczy jest równoznaczne ze spasowaniem tury.

Schemat działania

1. Podejrzuj posiadane karty.
2. Jeżeli posiadasz bezpieczne zagranie, wykonaj je. Pierwszeństwo nadawane jest zagraniom lawinowym, zaś w razie konfliktu wygrywa losowa karta o najniższym numerze.
3. Jeżeli możesz spasować turę, a ruch ten nie przeszkodzi żadnemu z pozostałych graczy w wykonaniu jednej z akcji od 2 do 5, zrób to.
4. Jeżeli posiadasz bezużyteczną kartę, odrzuć ją.
5. Jeżeli jest to możliwe, spasuj turę.
6. Jeżeli posiadasz kartę, której kopia znajduje się w ręce innego gracza, odrzuć ją.
7. Jeżeli posiadasz kartę, która nie jest krytyczna, odrzuć ją.
8. Odrzuć losową kartę krytyczną o najwyższym numerze.

Osiągi



Rysunek 4.2: Wyniki agenta SmartCheater (rozmiar próby: 1000 gier)

Jak można oczekiwać po agencie, który posuwa się do oszustwa bliskiego do doskonałego, jego wyniki są bardzo wysokie - nawet w przypadku partii na dwóch graczy, które cechują się największymi dysproporcjami w rozgrywce. Warto zauważyć, że istnieją rozdania cechujące się tak wysokim stopniem trudności, że nawet ten agent uzyskuje w nich mniej niż 20 punktów.


4.3. Erratic

Strategia agenta Erratic polega na wykonywaniu serii przypadkowych ruchów.

Schemat działania

- Wylosuj jedną legalnych akcji (zagraj kartę, odrzuć kartę, udziel podpowiedzi).
- Losowo wybierz detale ruchu, po czym go wykonaj.

Osiągi



Rysunek 4.3: Wyniki agenta Erratic (rozmiar próby: 1000 gier)

Agent wykonujący wyłącznie losowe ruchy jest pierwszym, który nie oszukuje. Niestety, jak można było przewidywać, przegrywa on większość gier. Jest to spowodowane brakiem mechanizmu, który powstrzymywałby go przed zagrywaniem kart, które nie są bezpieczne. Szansa na udzielanie informacji, które w tym przypadku są bezużyteczne, nie zaburza wyników, gdyż wykorzystanie żetonu podpowiedzi nie prowadzi do eskalacji progresu gry - jeżeli nie dobrano ostatniej karty z talii.

4.4. StoppedClock


Agent StoppedClock rozszerza strategię agenta Erratic: wykonuje losowe ruchy, które nie mogą doprowadzić do utraty żetonów życia. Jego postępowanie, choć bardzo chaotyczne, czasem prowadzi do wysokich punktacji, zgodnie z maksymą: “nawet zepsuty zegar dwa razy na dobę pokazuje właściwą godzinę”.

Schemat działania

Ruch agenta polega na zbadaniu, które z trzech dostępnych akcji są legalne, a następnie wylosowaniu i wykonaniu jednej z nich. Ponieważ tylko druga i trzecia akcja mogą wzajemnie się wykluczać, gracz zawsze będzie w stanie wykonać co najmniej jeden z ruchów. Dostępne akcje to:

- Jeżeli posiadasz bezpieczne zagranie, wykonaj je.
- Odrzuć losową kartę, priorytetyzując tę, która ma najmniej ujawnionych informacji. Akcja nie może być wykonana, jeżeli na planszy znajduje się osiem żetonów podpowiedzi.
- Wybierz losowego gracza, który posiada co najmniej jedną kartę o niepełnej informacji, wylosuj jedną, po czym losowo podpowiedz kolor lub numer wybranej karty, jeżeli nie zostały one uprzednio ujawnione. Jeżeli wszyscy gracze posiadają komplet informacji, spaszuj turę.

Osiągi



Rysunek 4.4: Wyniki agenta StoppedClock (rozmiar próby: 1000 gier)

Agent ma on nikłą szansę na uzyskanie wysokich wyników, a jego konstrukcja nigdy nie pozwoli na wygraną. Jest to spowodowane ograniczeniem, które umożliwia

programowi funkcjonowanie: wykonywane ruchy muszą być bezpieczne, co koliduje z ograniczoną liczbą żetonów odpowiedzi.

4.5. SimpleDistrustful

Agent SimpleDistrustful imituje postępowanie człowieka, który po raz pierwszy gra w Hanabi: wykonuje wyłącznie bezpieczne ruchy, lecz robi to umiejętnie, gdyż potrafi przeprowadzać pewne wnioskowania, które na jego miejscu mogłyby dokonać osoby o podstawowej znajomości zasad. Program nie udziela redundantnych odpowiedzi, stroni od odrzucania kart, które mogą się jeszcze przydać, a także rozumie, że niektóre karty zawsze można bezpiecznie zagrać lub odrzucić - mimo posiadania o nich niepełnej informacji.

Nowe pojęcia

- **Inferowalna karta:**

Użyteczności niektórych kart można dociec poprzez analizę aktualnego stanu rozgrywki. Przykładowo: na początku gry zawsze można zagrać dowolną kartę z numerem 1, niezależnie od tego, czy jej kolor został ujawniony. Podobnie, jeżeli nie odrzucono ani nie zagrano żadnej karty o numerze 4, żadna taka karta nie może być krytyczna. Karty o takiej właściwości nazywamy inferowalnymi, czyli dającymi się wywnioskować. Karty ujawnione są trywialnie inferowalne.

- **Wartościowa odpowiedź:**

Zdarzają się sytuacje, w których udzielanie pewnych informacji jest niepożądane. Przykładowo: jeżeli dwóch lub więcej uczestników rozgrywki posiada kopię danej karty, warto skupić się ujawnianiu wyłącznie jednej z nich. Wartościowa odpowiedź to taka, która jest lokalnie optymalna, gdyż unika powtarzania znanych informacji.

- **Najbliższy gracz:**


Uczestnik rozgrywki, który po zakończeniu akcji aktualnego gracza wykona ruch najwcześniej.

Schemat działania

1. Jeżeli posiadasz inferowalnie bezpieczne zagranie, wykonaj je.
2. Jeżeli jest to możliwe, wybierz najbliższego gracza, któremu możesz udzielić wartościowej odpowiedzi, po czym zrób to, nadając priorytet kartom o niższych numerach.
3. Jeżeli posiadasz nieujawnioną kartę, odrzuć ją.

4. Jeżeli posiadasz kartę, która nie jest inferowalnie krytyczna, odrzuć ją.
5. Odrzuć losową kartę.

Osiągi



Rysunek 4.5: Wyniki agenta SimpleDistrustful (rozmiar próby: 1000 gier)

Agent nie uzyskuje wysokich wyników, gdyż opiera swoje działania na przeciętnej strategii. Udzielanie wyłącznie wartościowych informacji skłania graczy do zagrywania kart, lecz często nie wystarcza do ochrony kart krytycznych - nieujawnione karty wymagają pewnej formy ochrony, gdyż mogły być dobrane dopiero niedawno. Szczególnie zawodzą wyniki rozgrywek dla dwóch graczy, które cechują się nadzwyczaj wysoką niestabilnością.

4.6. Distrustful

Agent Distrustful dopracowuje strategię stosowaną przez SimpleDistrustful. Program nadal gra zachowawczo, lecz ma do dyspozycji maksymalnie rozszerzony system dedukcji. Aby zminimalizować prawdopodobieństwo odrzucania kart krytycznych, został on dodatkowo usprawniony o konwencję, która chroni najnowsze karty poprzez nadawanie im wysokich priorytetów. Aby zwiększyć potencjalną przydatność

każdej z dokonywanych akcji, agent dynamicznie dostosowuje swój sposób postępowania do aktualnego stanu rozgrywki i zmienia priorytety manewrów, w zależności od ilości pozostałych żetonów podpowiedzi. Pozwala to na dopasowywanie przyjmowanej taktyki, przy jednoczesnym zachowaniu zasad ugruntowanych przez narzuconą strategię.

Nowe pojęcia

- **Pułap jakościowy:**

Jedna z miar używanych w funkcjach oceniających przydatność ruchów: jeżeli uzyskana przez daną akcję nota jest niższa od pułapu, jest ona dyskwalifikowana jako niewystarczająco pomocna.

- **Heurystycznie wartościowa akcja:**

Niektóre akcje, takie jak bezpieczne zagranie, są w oczywisty sposób korzystne dla postępu gry. Niestety, przypisanie części ruchów jednoznacznej wartości liczbowej, wskazującej na jej przydatność w kontekście danego momentu rozgrywki, jest trudnym zadaniem, gdyż pełna analiza możliwych następstw akcji wymagałaby wysokiego nakładu mocy obliczeniowej. Aby uniknąć tego problemu, można zastosować funkcje heurystyczne, które przybliżają wartości poszukiwanych ocen. Akcja, która uzyska najwyższą notę, a także będzie wyższa od zadanego pułapu jakościowego, jest nazywana heurystycznie optymalną.

- **Najstarsza (najmłodsza) karta:**

Karta, która znajduje się w ręce danego gracza od największej (najmniejszej) ilości tur. W razie konfliktu za najstarszą (najmłodsza) kartę uznawana jest ta wysunięta najbardziej na lewo.

Schemat działania

Agent jest złożony z siedmiu modułów, które są rozważane po kolei w jednej z trzech konfiguracji. Każdy moduł, poza ostatnim, może zawieść. Ich kolejność zależy od ilości posiadanych żetonów podpowiedzi:

- Mniej niż 3 żetony: sekwencja 1, 2, 5, 3, 4, 7 (moduł 6 nie jest używany).
- Od 3 do 7 żetonów: sekwencja 1, 2, 3, 4, 5, 6, 7.
- Dokładnie 8 żetonów: sekwencja 1, 2, 3, 4, 6, 5, 7.

Używane moduły to:

1. “Necessary tip”:

Jeżeli najbliższy gracz planuje w kolejnym ruchu odrzucić kartę krytyczną, powstrzymaj go poprzez udzielenie odpowiedniej podpowiedzi.

2. “Obvious play”:

Jeżeli posiadasz inferowalnie bezpieczne zagranie, wykonaj je, nadając priorytet kartom o niższych numerach.

3. “Good play tip”:

Jeżeli posiadasz co najmniej dwa żetony podpowiedzi i istnieje heurystycznie wartościowa podpowiedź, która umożliwi innemu graczowi inferowalnie bezpieczne zagranie, udziel jej.

4. “Discard tip”:

Jeżeli posiadasz co najmniej dwa żetony podpowiedzi i istnieje heurystycznie wartościowa podpowiedź, która umożliwi innemu graczowi odrzucenie inferowalnie bezużytecznej karty, udziel jej.

5. “Obvious discard”:

Jeżeli posiadasz inferowalnie bezużyteczną kartę, odrzuć ją.

6. “Mediocre play tip”:

Jeżeli posiadasz co najmniej dwa żetony podpowiedzi, spróbuj wykonać akcję modułu numer 3 (“Good play tip”), ale ze znacznie niższym pułapem jakościowym.

7. “Guess discard”:

- (a) Jeżeli posiadasz nieujawnione karty, odrzuć najstarszą z nich.
- (b) Jeżeli posiadasz karty, które nie są inferowalnie krytyczne, odrzuć najstarszą z nich.
- (c) Odrzuć najstarszą kartę.

Zmiana kolejności manewrów pozwala na kontrolowanie priorytetów agenta: im mniej żetonów podpowiedzi znajduje się w grze, tym bardziej nagła staje się potrzeba ich odzyskania. Nigdy nie wiadomo, czy i kiedy któryś z graczy dobierze kartę wymagającą natychmiastowej interwencji w formie dodatkowych informacji. Jest to powód, dla którego moduły udzielające podpowiedzi do kart niebędących krytycznymi zawodzą przy próbie wykorzystania ostatniego z żetonów.


Wagi funkcji heurystycznych zostały dobrane eksperymentalnie. Poza sprawdzaniem, czy dana podpowiedź jest wartościowa, na werdykt algorytmu wpływają między innymi następujące czynniki:

- stopień ujawnienia karty

- czy zagranie karty jest lawinowe
- ilość kart, które muszą być zagrane, zanim karta będzie bezpieczna
- odległość właściciela karty od aktualnego gracza
- numer karty
- wagi kart, które zostaną ujawnione wraz z rozważaną kartą

Początkowo, moduł numer 1 (“Necessary tip”) przyjmował inną formę. Zamiast ostrzegać graczy przed odrzucaniem krytycznych kart natychmiast po wykryciu zagrożenia, udzielenie kluczowej informacji było odwlekane aż do tury gracza, który jako ostatni mógł zapobiec nieszczęściu. W praktyce doprowadzało to do powstawania cykli, w których gracze naprzemiennie udzielali odpowiedzi i odrzucali karty, przez co częstotliwość zagrań drastycznie spadała. Choć pierwotny moduł znacznie pogarszał wyniki agenta Distrustful, jego zrewidowana wersja stanowi serce kolejnego, bardziej zaawansowanego agenta.

Osiągi



Rysunek 4.6: Wyniki agenta Distrustful (rozmiar próby: 1000 gier)

Mimo znacznego wzmocnienia strategii agenta SimpleDistrustful, osiągane wyniki nadal nie zachwycają. Gracze udzielają heurystycznie wartościowych odpowiedzi, chronią krytyczne karty poprzez system wieku i oszczędzają żetony na czarną godzinę - trudno jednak doszukiwać się między nimi głębszej współpracy, która jest kluczowa dla wysokich osiągnięć. Zagrywane są wyłącznie karty inferowalnie bezpieczne, co, nawet przy bardzo ostrożnej i wydajnej komunikacji, nie wystarcza do podjęcia równej walki z szybko kurczącą się ilością żetonów odpowiedzi. Aby przekroczyć wyczekiwany próg średniej ilości 20 punktów, potrzeba strategii, która dopuszcza pewne ryzyko.

4.7. Trustful

Poprzedników agenta Trustful nękały dwa zasadnicze problemy. Są to: trudność związana z efektywnym przekazywaniem informacji, a także wystrzeganie się zagrań, które nie są bezpieczne. Obie te przeszkody można pokonać poprzez ustanowienie protokołu komunikacji, który nadaje niektórym akcjom dodatkowego, implicytnego znaczenia, rozumianego przez pozostałych uczestników rozgrywki. Podpowiedzi udzielane przez agenta przekazują nie tylko informacje o kartach, ale i plan działania na kolejne tury. Aby obejść problem ograniczonej ilości żetonów odpowiedzi, program potrafi, przy spełnieniu odpowiednich warunków, wykonywać ruchy, które nie są inferowalne, lecz mają bardzo wysokie prawdopodobieństwo bycia bezpiecznymi.

Nowe pojęcia

- **Obietnica:**

Jeżeli agent udzieli informacji, która, zgodnie z protokołem komunikacji, wyznacza plan zagrywania kolejnych kart, taką odpowiedź nazywamy obietnicą.

- **Komunikat:**

Podpowiedź, która nie jest obietnicą.

- **Podpowiedź ratunkowa:**

Heurystycznie wartościowa podpowiedź, będąca obietnicą lub komunikatem, ignorująca pułap jakościowy heurystyki.

- **Weto:**

Akt zdjęcia efektu obietnicy z karty. Jeżeli istnieje podpowiedź ratunkowa, która umożliwia danemu graczowi wykonanie jakiegoś ruchu, weto polega na jej udzieleniu, w przeciwnym wypadku weta dokonuje się poprzez ujawnienie danej karty.

Schemat działania

Agent posiada dwie kategorie odpowiedzi: obietnice oraz komunikaty. Ustalenie ich typu odbywa się według następującego schematu:

1. Jeżeli gracz otrzyma od swojego bezpośredniego poprzednika odpowiedź obejmującą kartę, która miała zostać właśnie odrzucona, odpowiedź jest komunikatem.
2. Jeżeli gracz otrzyma od swojego bezpośredniego poprzednika dowolną odpowiedź, gdy jedna z kart objętych obietnicą miała zostać właśnie zagrana, ta karta jest wetowana, a typ odpowiedzi jest rozpatrywany ponownie, z pominięciem tego punktu schematu.
3. Jeżeli gracz otrzyma odpowiedź wskazującą na numer, którego poprawne zagranie byłoby niemożliwe w turze podpowiadającego gracza, odpowiedź jest komunikatem.
4. Odpowiedź jest obietnicą.

Podobnie jak w przypadku agenta *Distrustful*, program składa się z dziesięciu modułów, które są rozważane po kolei w jednej z czterech konfiguracji. Każdy moduł, poza ostatnim, może zawieść. Ich kolejność zależy od ilości posiadanych żetonów odpowiedzi:

- Mniej niż 3 żetony: sekwencja 1, 2, 3, 9, 4, 5, 10 (moduły 6, 7, 8 nie są używane).
- Od 3 do 5 żetonów: sekwencja 1, 2, 3, 4, 5, 9, 10 (moduły 6, 7, 8 nie są używane).
- 6 lub 7 żetonów: sekwencja 1, 2, 3, 4, 5, 9, 6, 7, 10 (moduł 8 nie jest używany).
- Dokładnie 8 żetonów: sekwencja 1, 2, 3, 4, 5, 6, 7, 8, 9, 10.

Używane moduły to:

1. “Necessary tip”:

Rozważ możliwe ruchy najbliższego gracza:

- (a) Jeżeli może niepoprawnie zagrać kartę objętą obietnicą, lecz posiadasz inferowalnie bezpieczne zagranie, które sprawia, że będzie ona zagrana poprawnie, wykonaj je - w przeciwnym wypadku zawetuj kartę.
- (b) Jeżeli może odrzucić kartę krytyczną, lecz istnieje odpowiedź ratunkowa, która umożliwia mu wykonanie innego ruchu, udziel jej - w przeciwnym wypadku ujawnij kartę, priorytetyzując informację o numerze.

2. “Obvious play”:

Jeżeli posiadasz inferowalnie bezpieczne zagranie, wykonaj je, nadając priorytet kartom o niższych numerach.

3. “Hinted play”:

Jeżeli posiadasz karty objęte obietnicą, których zagranie nie może być w oczywisty sposób niepoprawne, zagraj tę najbardziej wysuniętą na lewo, nadając priorytet kartom o ujawnionym numerze i wybierając spośród nich te, których numer jest najniższy.

4. “Play tip”:

Jeżeli istnieje heurystycznie wartościowa podpowiedź lub obietnica, która umożliwi innemu graczowi bezpieczne lub inferowalnie bezpieczne zagranie, udziel jej.

5. “Discard tip”:

Jeżeli istnieje heurystycznie wartościowa podpowiedź, która umożliwi innemu graczowi odrzucenie inferowalnie bezużytecznej karty, udziel jej.

6. “Risky tip”:

Spróbuj wykonać akcję modułu numer 4 (“Play tip”) z obniżoną karą za błędne obietnice i zwiększonym pułapem jakościowym.

7. “Save tip”:

Jeżeli istnieje podpowiedź ratunkowa ujawniająca kartę krytyczną, którą można wykonać w trybie komunikatu, wykonaj ją.

8. “Information tip”:

Spróbuj wykonać akcję modułu numer 4 (“Play tip”) ze zwiększoną nagrodą za udzielanie podpowiedzi w trybie komunikatu.

9. “Obvious discard”:

Jeżeli posiadasz inferowalnie bezużyteczną kartę, odrzuć ją.

10. “Guess discard”:

- (a) Jeżeli posiadasz nieujawnione karty, odrzuć najstarszą z nich.
- (b) Jeżeli posiadasz karty, które nie są inferowalnie krytyczne, odrzuć najstarszą z nich.
- (c) Odrzuć najstarszą kartę.

Wagi funkcji heurystycznych ponownie zostały dobrane eksperymentalnie, lecz sposób oceny akcji znacznie różni się od tego znanego z agenta Distrustful. Z racji

na ambiwalencję udzielanych typów podpowiedzi, należy uważać nie tylko na jakość przekazywanych informacji, ale i ich znaczenie w kontekście protokołu komunikacji.

Poza czynnikami wyszczególnionymi podczas analizy agenta Distrustful, na werdykt algorytmu wpływają między innymi:


- czy podpowiedź jest obietnicą
- czy komunikat zostanie uznany za obietnicę, mimo, że tego nie chcemy
- czy karta może stać się grywalna w turze danego gracza
- czy karta jest pod działaniem efektu obietnicy
- czy podpowiedź zniweczy przydatną obietnicę
- czy podpowiedź jest ryzykowna
- pozostała ilość żetonów życia
- kolejność ujawnianych kart w ręce

Podpowiadanie kart w trybie obietnicy rzadko przebiega w bezproblemowy sposób: karty tworzące częściowy porządek w ręce gracza to rzadkie zjawisko. Jest to powód, dla którego funkcje heurystyczne agresywnie zaniżają noty obietnic, których pierwszy element jest niepoprawny, lecz relaksują kary dla tych podpowiedzi, które zaczynają się w sposób umożliwiający co najmniej jedno bezpieczne zagranie.

Udzielanie podpowiedzi podlegają pewnemu rygorowi, lecz czasami potencjalny zysk z udzielenia informacji o wielu kartach naraz przeważa nad ryzykiem związanym z niepoprawnością obietnicy. Ponieważ agent stara się zachowywać co najmniej jeden żeton podpowiedzi na takie przypadki, ryzyko niefortunnego zagrania drastycznie spada. Niestety, nadal może dojść do sytuacji, w których gracze tracą żetony życia poprzez niepoprawne zagrania. Aby temu zapobiec, agent ogranicza zaufanie do innych graczy, gdy w grze pozostał ostatni żeton życia - zagrywane są wyłącznie te karty objęte obietnicą, które zostały podpowiedziane pojedynczo. W ten sposób całkowicie eliminowane jest ryzyko niebezpiecznych zagrań, lecz agent nadal nie degeneruje swojej strategii do tej znanej z agenta Distrustful.

Strategia agenta nie jest przystosowana do rozgrywek dwuosobowych, gdyż udzielenie dowolnej podpowiedzi wetuje kartę, która miała szansę być właśnie zagrana. Prowadzi to do konieczności omijania systemu obietnic. Można to osiągnąć wyłącznie poprzez wykonywanie jednej z pozostałych akcji, co jest trudnym zadaniem, gdyż wiąże się to z koniecznością dobrej znajomości własnej ręki.

Osiągi



Rysunek 4.7: Wyniki agenta Trustful (rozmiar próby: 1000 gier)

Agent Trustful nie tylko potrafi przekroczyć próg 20 punktów, ale i zdarza mu się wygrać: zastosowanie protokołu implicytnej komunikacji pozwoliło wynieść osiągi sztucznej inteligencji na nowy poziom. Niestety, strategia programu nie jest przystosowana do rozgrywek dwuosobowych, co objawia się wysoką niestabilnością algorytmu. Wartym zaobserwowania faktem, który można odczytać z wykresu, jest wykładniczy wzrost trudności uzyskiwania kolejnych punktów, który występuje od pewnego momentu rozgrywki.


4.8. BayesianTrustful

Agent BayesianTrustful stanowi próbę odnalezienia nowych wag funkcji heurystycznych agenta Trustful, które pierwotnie zostały dobrane manualnie, w celu poprawy osiągnięć. W tym celu użyliśmy bayesowskiej metody optymalizacji hiperparametrów, korzystającej z procesów gaussowskich.

Podstawy teoretyczne

Bayesowska metoda optymalizacji to proces iteracyjny, oparty o twierdzenie Bayesa, który korzysta z wnioskowania statystycznego do analizy prawdopodobieństwa hipotez. Rozważmy przestrzeń hipotez \mathbb{H} , której elementom h przyporządkowane są początkowe prawdopodobieństwa $P(h)$, zwane *a priori*. Prawdopodobieństwo hipotezy $h \in \mathbb{H}$ po dokonaniu nowej obserwacji O można wyrazić wzorem $P(h|O)$, nazywanym *a posteriori*. Metoda bayesowska pozwala na aktualizację prawdopodobieństwa *a priori* hipotez w oparciu o nowe obserwacje. Przekłada się to na możliwość dokonywania wnioskowania statystycznego na temat rozkładu funkcji, która nie posiada wzoru jawnego.


Proces gaussowski to proces stochastyczny, który pozwala na określenie łącznego rozkładu prawdopodobieństwa (a także jego niepewności) wybranej rodziny nieparametrycznych funkcji \mathbb{F} . Polega on na konstrukcji prawdopodobieństw *a priori*, które można aktualizować poprzez kolejne obserwacje, co tworzy system przekonań o kształcie badanych funkcji.



Rysunek 4.8: Wizualizacja procesu gaussowskiego. Zielonymi plusami zaznaczono obserwacje, niebieskie krzywe to poprzednie przekonania *a posteriori*, zaś czerwona krzywa to ich średnia. Zaciemniona część wykresu wyznacza niepewność modelu. Źródło: [5]

Bayesowska metoda optymalizacji oparta o procesy gaussowskie polega na stworzeniu rozkładu *a priori* funkcji, której maksimum szukamy, a następnie próbkowaniu jej. Nowe obserwacje pozwalają na aktualizację prawdopodobieństw *a posteriori*. Wraz ze wzrostem ilości obserwacji przekonania algorytmu ulegają zmianie, a ponieważ proces gaussowski pozwala na identyfikację tych części funkcji, które najbardziej wymagają większej ilości obserwacji, metoda ta minimalizuje ilość próbkowań, potrzebnych do dalszych rozważań.

Osiągi



Rysunek 4.9: Wyniki agenta BayesianTrustful (rozmiar próby: 1000 gier)

Maksymalizowana była funkcja o 27 parametrach, odpowiadających wagom używanym w funkcjach heurystycznych. Jej wartość w punkcie została zdefiniowana jako średnia arytmetyczna wyników uzyskanych na przestrzeni 20 niezależnych rozgrywek czteroosobowych.

Algorytm optymalizujący, po zbadaniu kilku tysięcy próbek, znalazł nowy zestaw parametrów. Przeprowadzone testy wskazują na niewielki wzrost średniej ilości punktów dla grup trzech, czterech i pięciu graczy, kosztem zwiększonej wariancji. Agent Trustful nie był projektowany do przeprowadzania rozgrywek dwuosobowych, co szczególnie dobrze widać na wykresie - lepsze dostosowanie wag, które pomagają przy bardziej licznych grupach, pograża strategię dla dwóch graczy.

Na podstawie analizy wartości nowych wag można dociec, w jaki sposób zmieniła się strategia agenta:

- Moduł “Discard tip”, pomagający graczom w odrzucaniu bezużytecznych kart, udziela podpowiedzi wyłącznie w sytuacji, w której jest w stanie częściowo ujawnić jednocześnie co najmniej 4 karty (poprzednia wartość: 2)
- Moduł “Play tip”, zarządzający podpowiedziami dotyczącymi zagrań, w znacznym większym stopniu nagradza zagrania lawinowe, udzielanie informacji dalszym graczom oraz podpowiedzi dotyczące kart o niższych numerach, jednocześnie drastycznie zwiększając kary za nieprawidłowe obietnice i marginalizując znaczenie podpowiedzi będących komunikatami
- Moduł “Risky tip”, pozwalający na udzielanie podpowiedzi będących nieprawidłowymi obietnicami, otrzymał karę o takiej wysokości, która całkowicie wyklucza możliwość jego wykorzystania
- Moduł “Information tip”, pozwalający na udzielanie podpowiedzi będących komunikatami, ma zwiększony pułap jakościowy, co sprawia, że jest on znacznie rzadziej wykorzystywany

Podsumowując: agent jest mniej skłonny do udzielania podpowiedzi będących komunikatami i agresywnie penalizuje nieprawidłowe obietnice. Choć prowadzi to do uzyskania wyższej średniej punktowej, takie postępowanie destabilizuje algorytm i powoduje wzrost wariancji obserwowanych wyników.

4.9. Reinforced

WIP

Osiągi

Rozdział 5.

Niestandardowe modele rozgrywki

5.1. Dwa oblicza drużyn Hanabi

WIP

5.2. Pojedyunki XY

WIP

Rozdział 6.

Dalsze badania

WIP

Dodatek A

Uruchamianie interfejsu użytkownika

WIP

Bibliografia

- [1] J.-F. Baffier i in., *Hanabi is NP-complete, Even for Cheaters who Look at Their Cards*, 2017. URL: [link](#) (term. wiz. 26.01.2020)
- [2] A. Lerer, H. Hu, J. Foerster, N. Brown, *Building AI that can master complex cooperative games with hidden information*, 2019. URL: [link](#) (term. wiz. 26.01.2020)
- [3] T. Murphy, *The First Level of Super Mario Bros. is Easy with Lexicographic Orderings and Time Travel ...after that it gets a little tricky.*, 2013. URL: [link](#) (term. wiz. 26.01.2020)
- [4] B. Bouzy, *Playing Hanabi Near-Optimally*, 2017. URL: [link](#) (term. wiz. 26.01.2020)
- [5] Fernando Pérez-Cruz i in., *Gaussian Processes for Nonlinear Signal Processing: An Overview of Recent Advances*, 2013. URL: [link](#) (term. wiz. 26.01.2020)